

Изучение существующих методов аппроксимации

Для выбора оптимального подхода, проведём обзор основных классов методов, которые потенциально применимы к нашему кейсу:

1. Линейная и полиномиальная регрессия

- *Суть:* Модель пытается представить целевую метрику как сумму входных признаков с определёнными весами
- *Плюсы и минусы:* Быстро обучается, легко интерпретируется, но чистая линейная модель не может улавливать сложные нелинейные связи без ручного преобразования

2. Древовидные ансамбли (Random Forest, Gradient Boosting)

- *Суть:* Алгоритмы строят ансамбль решающих деревьев, где каждое дерево принимает решение на основе последовательных условий
- *Плюсы и минусы:* Отлично работают с нелинейными данными и пороговыми значениями, устойчивы к выбросам. Не умеют предсказывать значения за пределами границ обучающей выборки

3. Методы опорных векторов (SVR)

- *Суть:* Переносит данные в более высокое пространство размерностей, где пытается построить разделяющую гиперплоскость
- *Плюсы и минусы:* Хорошо работает на небольших выборках, но долго обучается при росте количества данных и требует сложной настройки параметров

4. Нейронные сети

- *Суть:* Набор связанных слоёв нейронов с нелинейными функциями активации
- *Плюсы и минусы:* Могут выучить любую зависимость, но требуют очень много данных для обучения

Выбор методов для экспериментов и их обоснование

На основе анализа специфики задачи для проведения экспериментов были выбраны два метода: линейная регрессия (с логарифмированием признаков, тк значения W , D различаются на порядки) (Baseline) и случайный лес (основной метод)

Обоснование выбора:

- **Ожидаемая форма зависимостей**

Из теории алгоритмов и структуры исследуемых подходов (A , B , C) можно выделить следующие особенности:

- **Нелинейность:** В подходе A время поиска зависит от глубины D и ширины W как $O(D \cdot \log W)$ или $O(D \cdot W)$. Это явно нелинейная зависимость. Чтобы линейная регрессия могла её уловить, мы применим логарифмирование признаков
- **Экспоненциальный рост:** В подходах B и C групповые операции вроде `ls` или `find` зависят от размера поддеревья, который при увеличении коэффициента заполнения F может расти экспоненциально

Из-за нелинейной природы и взаимного влияния параметров Random Forest выбран в качестве основного метода. За счёт своей структуры он может автоматически подстраиваться под особенности функций

- **Количество доступных данных**

Согласно плану формирования сетки, мы имеем **требуется уточнений:**

$$N = \text{точек измерений на один подход}$$

- **Требования к интерпретируемости**

- **Линейная регрессия** даёт максимальную интерпретируемость: знак и величина коэффициента перед признаком показывают, насколько сильно и в какую сторону меняется метрика при изменении признака
- **Random Forest** менее прозрачен, но он предоставляет оценку важности признаков. С помощью неё мы сможем построить график и наглядно показать, какой из параметров вносит наибольший вклад

- **Вычислительные ресурсы**

Поскольку обученные модели будут использоваться внутри рекомендателя, хотелось бы иметь хорошую скорость на этапе предсказания

- Линейная регрессия выполняет только операцию скалярного произведения, что работает мгновенно
- Обученный Random Forest тратит время только на проход по веткам деревьев фиксированной глубины, что также имеет константную сложность $O(1)$ относительно объема данных

Оба метода легковесны и не потребуют мощных вычислительных ресурсов ни при обучении, ни при работе рекомендателя.

- **Наличие корреляций между целевыми метриками**

Исходя из физики работы вычислительных систем, между нашими целевыми метриками ожидается сильная взаимосвязь:

- Пропускная способность (Throughput) и средняя латентность (Latency) связаны обратно пропорционально, чем выше задержки, тем меньше операций в секунду обрабатывает система
- 99-й процентиль латентности очевидно связан со средней латентностью, но характер этой связи **требует уточнения после получения реальных данных**
- Потребление памяти (Memory) теоретически не должно напрямую зависеть от временных характеристик. В основном будет зависеть от структуры данных (D, W, F)

Точный характер и сила корреляций требуют уточнения на этапе анализа собранных данных