

Изучение существующих методов аппроксимации

Для выбора оптимального подхода, проведём обзор основных классов методов, которые потенциально применимы к нашему кейсу:

1. Линейная и полиномиальная регрессия

- *Суть:* Модель пытается представить целевую метрику как сумму входных признаков с определёнными весами
- *Плюсы и минусы:* Быстро обучается, легко интерпретируется, но чистая линейная модель не может улавливать сложные нелинейные связи без ручного преобразования

2. Древоидные ансамбли (Random Forest, Gradient Boosting)

- *Суть:* Алгоритмы строят ансамбль решающих деревьев, где каждое дерево принимает решение на основе последовательных условий
- *Плюсы и минусы:* Отлично работают с нелинейными данными и пороговыми значениями, устойчивы к выбросам. Не умеют предсказывать значения за пределами границ обучающей выборки

3. Методы опорных векторов (SVR)

- *Суть:* Переносит данные в более высокое пространство размерностей, где пытается построить разделяющую гиперплоскость
- *Плюсы и минусы:* Хорошо работает на небольших выборках, но долго обучается при росте количества данных и требует сложной настройки параметров

4. Нейронные сети

- *Суть:* Набор связанных слоёв нейронов с нелинейными функциями активации
- *Плюсы и минусы:* Могут выучить любую зависимость, но требуют очень много данных для обучения

Выбор методов для экспериментов и их обоснование

На основе анализа специфики задачи для проведения экспериментов были выбраны два метода: линейная регрессия с регуляризацией R2 (Ridge) в качестве базового уровня (baseline) и ансамбль решающих деревьев (Random Forest) в качестве целевой нелинейной модели. Переход к анализу сложной модели обосновывается системой критериев достаточности линейного приближения.

Линейная (Ridge) модель считается математически недостаточной для аппроксимации характеристик файловой системы, если выполняется хотя бы одно из следующих условий:

1. **Критерий детерминации:** R^2 на тестовой выборке < 0.7 хотя бы для одной из четырёх целевых системных метрик
2. **Критерий структуры остатков:** Наличие выраженной систематической структуры или гетероскедастичности в остатках (вместо распределения в виде случайного гауссова шума вокруг нулевой линии на графике «остатки vs предсказание»)

Обоснование выбора:

• Ожидаемая форма зависимостей

Из теории алгоритмов и структуры исследуемых подходов (A, B, C) можно выделить следующие особенности:

- **Нелинейность:** В подходе A время поиска зависит от глубины D и ширины W как $O(D \cdot \log W)$ или $O(D \cdot W)$. Это явно нелинейная зависимость. Чтобы линейная регрессия могла её уловить, мы применим логарифмирование признаков

- **Экспоненциальный рост:** В подходах В и С групповые операции вроде `ls` или `find` зависят от размера поддерева, который при увеличении коэффициента заполнения F может расти экспоненциально
- **Количество доступных данных**
Согласно плану формирования сетки, мы имеем:

$$N \approx 1000 \text{ точек измерений на один подход}$$

- **Требования к интерпретируемости**
 - **Линейная регрессия** даёт максимальную интерпретируемость: знак и величина коэффициента перед признаком показывают, насколько сильно и в какую сторону меняется метрика при изменении признака
 - **Random Forest** менее прозрачен, но он предоставляет оценку важности признаков. С помощью неё мы сможем построить график и наглядно показать, какой из параметров вносит наибольший вклад

- **Вычислительные ресурсы**

Поскольку обученные модели будут использоваться внутри рекомендателя, хотелось бы иметь хорошую скорость на этапе предсказания

- Линейная регрессия выполняет только операцию скалярного произведения, что работает мгновенно
- Обученный Random Forest тратит время только на проход по веткам деревьев фиксированной глубины, что также имеет константную сложность $O(1)$ относительно объема данных

Оба метода легковесны и не потребуют мощных вычислительных ресурсов ни при обучении, ни при работе рекомендателя.

- **Наличие корреляций между целевыми метриками**

Исходя из физики работы вычислительных систем, между нашими целевыми метриками ожидается сильная взаимосвязь:

- Пропускная способность (Throughput) и средняя латентность (Latency) связаны обратно пропорционально, чем выше задержки, тем меньше операций в секунду обрабатывает система
- 99-й перцентиль латентности очевидно связан со средней латентностью
- Потребление памяти (Memory) теоретически не должно напрямую зависеть от временных характеристик. В основном будет зависеть от структуры данных (D, W, F)

Проектирование признаков

Чтобы повысить точность аппроксимации и помочь линейной модели лучше улавливать особенности файловых систем, был проведён синтез новых нелинейных признаков. Базовый набор параметров включает в себя: глубину дерева (D), ширину папки (W), общее количество файлов (F) и относительную частоту вызова конкретных операций op_i

Математическое обоснование новых признаков

1. Логарифмирование структурных параметров ($\log D, \log W$)

Входные параметры структуры данных могут различаться на несколько порядков. Из-за этого линейная регрессия начинает сильно ошибаться на краях выборки. Так же известно, что время поиска элемента в структуре часто зависит от параметров нелинейно (например, $O(D \cdot \log W)$). Это позволяет свести мультипликативные эффекты к аддитивным

2. Конструирование признаков (Feature Engineering)

Для компенсации нелинейности базовый вектор параметров расширен синтетическими признаками:

- **Геометрия структуры:**

- `estimated_nodes` - оценка числа узлов дерева через сумму геометрической прогрессии:

$$\text{estimated_nodes} = F \cdot \sum_{i=0}^D W^i = F \cdot \frac{W^{D+1} - 1}{W - 1}$$

- `log_estimated_nodes` = $\ln(1 + \text{estimated_nodes})$ - стабилизирует дисперсию

- **Агрегация профиля нагрузки для :**

- `heavy_scan_ops` ($p_{\text{ls}} + p_{\text{find}}$) - суммарная доля тяжелых сканирующих операций
- `mutation_ops` ($p_{\text{write}} + p_{\text{mv}}$) - интенсивность изменения топологии дерева; снижает коллинеарность долей

- **Эффекты локальности и перекрестные связи:**

- `zipf_depth_interaction` ($\text{zipf_s} \cdot \ln(D)$) - усиление эффекта неравномерности доступа с ростом глубины. При `distribution == uniform` параметру `zipf_s` принудительно присваивается 0.0.
- `nodes_x_read` ($\text{estimated_nodes} \cdot p_{\text{read}}$) - затраты на удержание «холодных» узлов при поиске.
- `nodes_x_mutation` ($\text{estimated_nodes} \cdot \text{mutation_ops}$) - нагрузка от мутации больших деревьев (каскадные аллокации).
- `high_read_uniform` - бинарный флаг ($[p_{\text{read}} > 0.6] \wedge [\text{distribution_zipf} == 0]$) режима доминирующего чтения без кэширования путей.
- **Категориальные признаки:** Кодирование `distribution` через One-Hot Encoding (`drop_first=True`) выделяет бинарный признак `distribution_zipf`.

Анализ мультиколлинеарности и применение VIF

Поскольку признаки математически связаны, возникает проблема мультиколлинеарности (сильной линейной зависимости между предикторами). Для линейной регрессии это неприятно: веса модели становятся нестабильными

Для выявления сильно зависимых признаков мы будем использовать фактор инфляции дисперсии (VIF). Для каждого признака x_j он рассчитывается по формуле:

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

где R_j^2 - коэффициент детерминации линейной модели, в которой признак x_j выступает в роли целевой переменной, а все остальные признаки как в предикторы

Построение и обучение моделей регрессии

Масштабирование данных

Входные признаки имеют совершенно разные масштабы: объём памяти измеряется в байтах, коэффициент заполнения варьируется от 0 до 1, а логарифмы в единицах. Линейная регрессия чувствительна к масштабу, переменные с большими абсолютными значениями будут оказывать более сильное влияние на результат

Для устранения этого эффекта применяется стандартизация (Z-преобразование):

$$z = \frac{x - \mu}{\sigma}$$

где μ - среднее значение признака, а σ - стандартное отклонение

Использование цепочек регрессоров

В рамках исследования необходимо предсказать вектор из четырёх взаимосвязанных целевых метрик: объем памяти, среднюю задержку, 99-й перцентиль задержки и пропускную способность

Обучение независимых моделей для каждой метрики не учитывает физические связи внутри системы, например, то, что рост латентности снижает пропускную способность. Для решения этого использован подход цепочек регрессоров

Суть заключается в последовательном обучении регрессоров, где каждый следующий шаг принимает на вход не только матрицу признаков, но и предсказания всех предыдущих моделей

В качестве базового алгоритма внутри цепочки используется регрессия с L_2 -регуляризацией

$$L_{\text{Ridge}}(w) = \frac{1}{n} \sum_{i=1}^n (y_i - w^T x_i)^2 + \alpha \|w\|^2$$

Параметр α подбирается экспериментально и отвечает за подавление весов при избыточных признаках

Кросс-валидация и оценка качества


Исходный датасет разделяется в классическом соотношении: 80% данных отводится под обучение и валидацию, 20% под тестирование

Подбор гиперпараметра регуляризации α и порядок регрессоров проводятся с помощью кросс-валидации на 5 блоков. Обучающая выборка делится на 5 равных частей, модель последовательно обучается на 4 из них и проверяется на оставшейся части

Комплексный визуальный анализ экспериментальных данных

Сравнительный анализ совместного распределения задержек (p99 vs avg_latency)


Для детального изучения структуры задержек в области стабильной работы системы (с отсечением экстремальных выбросов по порогу $p99_latency_us < 350$ мкс) были проанализированы разделенные графики рассеяния с единым масштабом осей для подходов А, В и С



1. **Подход А (Наивное дерево)** Большинство точек сгруппировано в безопасной зоне низких задержек (до 5 мкс по $avg_latency$ и 50 мкс по $p99$). Однако при усложнении поиска линейная зависимость теряется, и график начинает сильно ветвиться. При росте средней задержки всего до 10–15 мкс происходят резкие скачки $p99$ вверх (до 250+ мкс). Это показывает, что наивное дерево теряет стабильность на тяжелых операциях, выдавая непредсказуемые выбросы


2. **Подход В (Гибрид с хэш-таблицей)** График вытянут в строгий вертикальный столб: средняя задержка намертво зажата в узком диапазоне (до 5–7 мкс), но разброс р99 огромен (до 340+ мкс). За счет поиска за $O(1)$ архитектура отлично сдерживает рост среднего времени ответа. Платой за это становятся редкие, но тяжелые операции (коллизии, рехэширование или инвалидация кэша), которые вызывают огромные всплески хвостовой латентности
3. **Подход С (хеш-таблица)** Здесь видна четкая ступенчатая зависимость - точки собираются в изолированные «островки» в районах 7, 18 и 33 мкс по оси X. Подход деградирует предсказуемо: р99 растет строго пропорционально средней задержке. Разделение на кластеры указывает на явные шаги в архитектуре (например, переход на новый уровень вложенности или чтение глубоких поддиректорий)

Плотности распределения пропускной способности `throughput_ops_sec`



Исследование профилей памяти

Распределение потребления памяти в зависимости от подхода и фактора заполнения (F)




Подход В демонстрирует самые высокие показатели потребления памяти по всем ключевым метрикам: у него наибольшее медианное значение (более $3 \cdot 10^5$ байт), самый высокий верхний квартиль, а также максимальный среди всех групп единичный выброс, достигающий почти 10^9 байт

Подходы А и С имеют схожие минимальные значения (около 10^3 байт) и сопоставимые нижние границы распределения. Однако подход А имеет более высокую медиану и более широкий межквартильный размах по сравнению с подходом С, что говорит о стабильно большем потреблении памяти в типичных случаях

Подход С выглядит наиболее эффективным с точки зрения экономии ресурсов, так как его медиана находится на самом низком уровне (примерно $1.5 \cdot 10^5$ байт), а основная масса данных сдвинута ниже, чем у остальных подходов. При этом во всех трех архитектурных решениях наблюдаются единичные аномальные выбросы в районе 10^8 – 10^9 байт, что указывает на наличие специфических ресурсоемких сценариев для каждого из вариантов

Матрица корреляций



(остальные данные имеют очень низкую корреляцию)

Сильная линейная зависимость задержек (0.95): Между avg_latency_us и p99_latency_us наблюдается сильнейшая корреляция. Это обусловлено тем, что при общем замедлении выполнения операций предсказуемо растут и максимальные задержки

Связь потребления памяти и времени выполнения (0.32–0.33): Рост memory_usage_bytes умеренно коррелирует с увеличением латентности. Это объясняется тем, что при увеличении объема хранимых данных (например, росте количества узлов или коэффициента заполнения F) усложняется аллокация памяти и увеличивается время обхода дерева или хэш-таблиц

Обратная зависимость пропускной способности (-0.11 и -0.17): Метрика throughput_ops_sec ожидаемо демонстрирует отрицательную корреляцию с задержками и памятью. Физический смысл очевиден: чем выше вычислительная стоимость одной операции и чем больше накладные расходы на управление памятью, тем меньше операций в секунду способна обработать система

Влияние глубины дерева D: Параметр D практически не влияет на задержки напрямую (0.09). Однако он имеет слабую отрицательную корреляцию с пропускной способностью (-0.26) и положительную с памятью (0.18), что указывает на системный эффект: увеличение вложенности путей незначительно снижает темп обработки операций и увеличивает накладные расходы на хранение данных

Перейдем к рассмотрению конкретных подходов, используя выше упомянутые методы анализа и обучения

Анализ подхода А

Инженерия признаков

Для подхода А сформирован расширенный набор из 12 признаков, включающий геометрические параметры, их логарифмы, перекрестные взаимодействия (nodes_x_read, nodes_x_mutation,

zipf_depth_interaction), бинарный признак high_read_uniform и параметры нагрузки. Расчёт VIF выявил критическую мультиколлинеарность (половина набора превышает порог $VIF > 10$):

Признак	VIF	Признак	VIF
zipf_s	27.94	logW	8.46
log_estimated_nodes	19.22	nodes_x_mutation	6.34
logD	16.02	F	5.77
zipf_depth_interaction	13.72	nodes_x_read	4.33
estimated_nodes	13.49	p_read	3.13
locality	13.26	high_read_uniform	1.41

Высокий VIF обусловлен двумя факторами: во-первых, функциональной взаимосвязью признаков размера дерева, которые математически выводятся друг из друга; во-вторых, дизайном сетки эксперимента, где параметры locality и zipf_s во всех профилях изменяются строго синхронно, что делает их индивидуальные эффекты статистически неразделимыми.

Фиксация базовой модели (Ridge)

На основе 5-блочной кросс-валидации (KFold) и перебора параметров в цепочке RegressorChain была выбрана конфигурация:

$\alpha = 0.8$, порядок звеньев avg_latency_us $\rightarrow$ throughput_ops_sec $\rightarrow$ memory_usage_bytes $\rightarrow$ p99_latency_us.


Выбор максимального $\alpha = 0.8$ обусловлен необходимостью стабилизации весов в условиях зафиксированной мультиколлинеарности. Выбранный порядок цепочки отражает физику процессов файловой системы: средняя задержка напрямую определяет пропускную способность ($r = -0.73$), память зависит от геометрии, а наиболее нелинейная метрика хвостовой латентности (p99) замыкает цепочку, агрегируя предсказания предыдущих звеньев.

Оценка модели линейного бейслайна:

Метрика	R^2	MAE	RMSE	MAPE	Max Error %
memory_usage_bytes	0.753	41.4 млн	56.8 млн	49736 %	1000388 %
avg_latency_us	0.270	2.40	6.57	169.1 %	914 %
p99_latency_us	0.326	33.62	77.20	804.7 %	6033 %
throughput_ops_sec	0.413	745918	1051097	111.5 %	4286 %


Линейная модель Ridge показала приемлемый результат только для memory_usage_bytes ($R^2 = 0.753$). Метрики латентности и пропускной способности не преодолели порог достаточности 0.7, что подтверждает неспособность линейной регрессии корректно разделить вклады сильно коррелированных факторов.

Анализ графика «Фактическое vs Предсказанное»





Для всех временных метрик (avg_latency, p99, throughput) наблюдается общий паттерн: в области высоких нагрузок точки систематически лежат ниже идеальной диагонали, что означает сильное занижение прогнозов моделью. Метрика памяти демонстрирует иной вид ошибки — стабильную переоценку на малых объемах данных и недооценку на больших масштабах.

Анализ остатков и обоснование перехода на Random Forest



Сильная корреляция остатков между `avg_latency_us` и `p99_latency_us` ($r = 0.92$) указывает на общий для обеих метрик неучтенный источник дисперсии. Ошибки памяти также умеренно связаны с задержками ($r = 0.32$ и $r = 0.40$), в то время как ошибки throughput практически изолированы.



Анализ весов выявил инверсию знаков коэффициентов из-за коллинеарности: для средней и хвостовой латентностей структурные признаки $\log D$ и $\log W$ получили крупные отрицательные веса (до -0.93), что физически противоречит логике работы дерева (рост размеров структуры должен увеличивать задержки). Линейное приближение признано несостоятельным из-за нелинейной природы процессов (аллокации памяти, сложность обхода дерева), в связи с чем осуществлен переход к нелинейным ансамблям.

Фиксация основной модели (Random Forest)

Оптимизация гиперпараметров ансамбля выполнялась методом `RandomizedSearchCV` на 5-блочной кросс-валидации. Лучшая конфигурация: количество деревьев $n = 200$,

`max_depth=10`,

`max_features=0.33`,

`min_samples_leaf=2`

(средний кросс-валидационный $R^2 = 0.6717$, OOB $R^2 = 0.5427$ для стартового звена). Структура и порядок цепочки регрессоров были сохранены для адекватного моделирования физических взаимосвязей между целевыми переменными.

Оценка модели:

Метрика	R^2 Ridge	R^2 RF	MAE RF	RMSE RF	MAPE RF
memory_usage_bytes	0.753	1.0000	145468	324847	63.71 %
avg_latency_us	0.270	0.7788	0.96	3.62	46.98 %
p99_latency_us	0.326	0.6968	14.83	51.77	140.72 %
throughput_ops_sec	0.413	0.6578	470530	802484	37.52 %

Переход к Random Forest дал качественный скачок точности: модель преодолела порог 0.7 для средней латентности (0.779) и вплотную приблизилась к нему для p99 (0.697) и пропускной способности (0.658). Метрика памяти достигла идеального значения $R^2 = 1.0000$ - дерево решений по сути восстанавливает детерминированную функцию, лежащую в основе синтетического `estimated_nodes`, без необходимости в линейной аппроксимации экспоненциальной зависимости

Рост точности подтверждает диагноз, поставленный по итогам анализа Ridge: проблема была не в отсутствии сигнала в признаках, а в неспособности линейной модели работать с нелинейными зависимостями (экспоненциальный рост размера дерева, пороговые эффекты доступа) на фоне мультиколлинеарного признакового пространства.

Анализ графика «Фактическое vs Предсказанное»





График подтверждает высокое качество аппроксимации: точки `memory_usage_bytes` идеально легли на диагональ $Y = X$. По временным метрикам основная масса векторов сгруппировалась вдоль целевой линии, а эффект занижения предсказаний сохранился исключительно в единичных пиковых точках экстремально высоких нагрузок.


Анализ остатков



Корреляция остатков `avg_latency` и `p99` снизилась с $r = 0.92$ до $r = 0.79$, подтверждая, что нелинейная модель частично развязала совместную дисперсию ошибок. Ошибки памяти полностью изолировались от временных параметров ($|r| \leq 0.07$), что доказывает способность деревьев решений эффективно использовать пороговые синергетические признаки.

Анализ важности признаков: извлечённые паттерны

Random Forest: Важность признаков по звеньям цепочки



Внутренняя структура важности факторов Random Forest полностью подтвердила исходные физические гипотезы:

- **avg_latency_us** на 50% определяется взаимодействием масштаба дерева со структурой трафика через признаки `nodes_x_read` (≈ 0.32) и `nodes_x_mutation` (≈ 0.18).
- **throughput_ops_sec** на 56% объясняется значением `pred_avg_latency_us`, полученным из предыдущего шага цепочки, что математически фиксирует строгую обратную связь задержек и потока операций.
- **memory_usage_bytes** на 90% управляется исключительно чистыми геофизическими параметрами размера дерева (`log_estimated_nodes`, `estimated_nodes`), игнорируя динамические предикторы задержек.
- **p99_latency_us** имеет выраженную композитную природу и извлекает более 65% сигнала из промежуточных предсказаний цепочки (`pred_avg_latency_us` ≈ 0.39 и `pred_throughput_ops_sec` ≈ 0.27).

Анализ подхода В

Подход В сохраняет дерево как основу, но добавляет хэш-таблицу «полный путь $\rightarrow$ узел». Это обеспечивает $O(1)$ -доступ при прямой адресации, но усложняет операцию перемещения (`mv`), требующую синхронизации обеих структур

Инженерия признаков

Для подхода В сформирован набор из 12 признаков: геометрические параметры (`logD`, `logW`), полный вероятностный профиль операций без агрегации (`p_ls`, `p_find`, `p_write`, `p_mv`, `p_read`), локальность доступа (`locality`), параметры распределения Ципфа (`zipf_s`, `zipf_depth_interaction`) и оценка масштаба (`estimated_nodes`, `log_estimated_nodes`).

Расчёт VIF показал характерную картину коллинеарности:

Признак	VIF	Признак	VIF
<code>p_ls</code>	15.10	<code>zipf_depth_interaction</code>	6.73
<code>p_read</code>	12.46	<code>locality</code>	5.89
<code>zipf_s</code>	9.70	<code>log_estimated_nodes</code>	5.67
<code>p_find</code>	8.76	<code>logW</code>	3.35
<code>p_write</code>	8.02	<code>p_mv</code>	3.18
<code>logD</code>	7.31	<code>estimated_nodes</code>	1.88

Критический порог ($VIF > 10$) превышают только `p_ls` и `p_read`. Это вызвано не дублированием параметров, а функциональной зависимостью. Параметр объема `estimated_nodes` ($VIF = 1.88$) здесь практически ортогонален остальным, в отличие от подхода А

Фиксация базовой модели (Ridge)

Кросс-валидация снова выбрала максимальную регуляризацию ($\alpha = 0.8$), что ожидаемо при текущей коллинеарности. Порядок цепочки полностью совпадает с подходом А, упрощая сравнение: `memory_usage_bytes` $\rightarrow$ `avg_latency_us` $\rightarrow$ `p99_latency_us` $\rightarrow$ `throughput_ops_sec`.

Оценка модели


Метрика	R^2	MAE	RMSE	MAPE	Max Error %
<code>memory_usage_bytes</code>	0.7459	98.66 млн	134.77 млн	79301.5 %	1061332 %

avg_latency_us	0.6034	3.09	4.83	376.1 %	5341 %
p99_latency_us	0.6735	62.45	94.27	2920.4 %	65920 %
throughput_ops_sec	0.5538	1.22 млн	1.73 млн	396.4 %	4745 %

Линейная регрессия Ridge показала недостаточное качество ($R^2 < 0.7$ для временных метрик). Однако результаты avg_latency_us (0.6034) и p99_latency_us (0.6735) почти вдвое лучше, чем у подхода A.


Хэш-таблица убирает зависимость стоимости поиска от глубины дерева D , делая связь латентности со структурой более линейной. Высокая относительная ошибка (MAPE) указывает на неспособность Ridge учитывать пороговые эффекты при росте estimated_nodes

Анализ графика «Фактическое vs Предсказанное»





- Память: Модель воспроизводит бимодальный паттерн (кластеры около 0 и $8 \cdot 10^8$), но внутри верхнего кластера уходит в регрессию к среднему, разделяя предсказания на две группы.
- Латентность и пропускная способность: Наблюдается системное «срезание» пиковых значений. Модель принимает экспоненциальный рост за линейный тренд, но в подходе В плато выходит на более высокий уровень, то есть точность теряется позже, чем в А

Анализ остатков и обоснование перехода на Random Forest



Анализ корреляции остатков выявил сильную связь между средней и хвостовой латентностью ($r = 0.81$). Линейный оператор Ridge не может изолировать общий нелинейный источник дисперсии (кэширование, задержки хэш-таблицы). Ошибки пропускной способности (throughput_ops_sec) почти не коррелируют с остальными метриками



- **p99_latency_us**: Доминирует `log_estimated_nodes` (+1.25), которому физически бессмысленно противодействуют `logD` (-0.95) и `logW` (-0.45) — признак нестабильности весов
- **throughput_ops_sec**: Главный вклад вносит `mean_latency` (+0.85), отражая обратную связь латентности и пропускной способности. Вероятности `p_read` (-0.25), `p_mv` (-0.17) и `p_write` (-0.15) снижают throughput сильнее, чем в А, из-за расходов на синхронизацию структур при mv

Линейная гипотеза признается несостоятельной, что оправдывает переход к Random Forest


Random Forest: подбор гиперпараметров и оценка

Оптимальная конфигурация леса: `n_estimators=200`, `max_depth=10`, `max_features=sqrt`, `min_samples_leaf=1`. Менее консервативные настройки (по сравнению с А) указывают на более слабую мультиколлинеарность признаков

Метрика	R^2	MAE	RMSE	MAPE
memory_usage_bytes	0.9996	1 618 333	5 450 234	181.09 %
avg_latency_us	0.8399	1.27	3.07	32.87 %
p99_latency_us	0.8386	27.33	66.27	54.18 %
throughput_ops_sec	0.9100	377 639	776 423	25.85 %

Случайный лес дает резкий прирост качества. В отличие от подхода А, все четыре метрики уверенно преодолевают порог $R^2 = 0.7$. Подход В оказывается более предсказуемым для ансамблей: $O(1)$ -доступ сглаживает критические нелинейности

Анализ графика «Фактическое vs Предсказанное» (RF)



- **Память:** Идеальное прилегание к линии
- **Латентность и throughput:** Плотное распределение вдоль диагонали с небольшим занижения.
- **p99_latency_us:** Обнаружено одно anomальное предсказание: факт ≈ 350 мкс предсказан как ≈ 990 мкс. Такой выброс в сторону переоценки уникален для подхода В и вызван редкой комбинацией признаков


Анализ остатков



Остаточная корреляция между avg_latency_us и p99_latency_us осталась высокой ($r = 0.77$). Так как этот паттерн повторяет результат подхода А, его причина это ограничение цепочечной структуры RF (модель p99 неизбежно наследует нескорректированную ошибку предыдущего звена)

Важность признаков

Random Forest: Важность признаков по звеньям цепочки



- **avg_latency_us:** Доминирует доля операций записи p_write (≈ 0.21), за ней идут log_estimated_nodes (≈ 0.145) и estimated_nodes (≈ 0.125). Модель сама выявила накладные расходы на синхронизацию хэш-таблицы при записи.
- **throughput_ops_sec:** Главный признак - pred_avg_latency_us (≈ 0.38). Также важны операции p_find (≈ 0.145) и p_mv (≈ 0.105), напрямую нагружающие хэш-таблицу.
- **memory_usage_bytes:** Более 70% важности делят estimated_nodes и log_estimated_nodes.
- **p99_latency_us:** В отличие от A, здесь pred_throughput_ops_sec (≈ 0.325) важнее, чем pred_avg_latency_us (≈ 0.275). Конкурентный доступ к хэш-таблице сначала вызывает просядку пропускной способности, которая затем транслируется в хвостовые задержки (p99)

Анализ подхода С

Инженерия признаков

Признаковое пространство С объединяет подходы А и В: сохранены перекрестные взаимодействия nodes_x_read и nodes_x_mutation (из А) и добавлены отдельные вероятности операций p_ls, p_find, p_write, p_mv, p_read (из В). Из набора полностью исключен параметр logD, что сократило размерность до 11 признаков.

Расчёт VIF показал наилучшую ортогональность среди всех конфигураций:

Признак	VIF	Признак	VIF
estimated_nodes	13.80	nodes_x_read	4.26

p_find	7.30	p_read	3.53
nodes_x_mutation	6.39	p_mv	2.60
p_ls	5.11	log_estimated_nodes	1.43
p_write	4.74	locality / logW	≈0.96-0.98

Порог $VIF > 10$ превышен только для `estimated_nodes`. Несмотря на минимальную коллинеарность, линейная модель ниже демонстрирует наихудшие результаты среди всех систем. Это доказывает, что главным ограничением здесь выступает экстремальная нелинейность зависимостей, а не избыточность признаков.


Фиксация базовой модели (Ridge) и оценка качества

Оптимальная конфигурация Ridge: $\alpha = 0.8$, порядок звеньев цепочки: `avg_latency_us` → `throughput_ops_sec` → `memory_usage_bytes` → `p99_latency_us` (совпадает с порядком RF для подхода А).

Метрика	R^2	MAE	RMSE	MAPE	Max Error %
memory_usage_bytes	0.6134	64.92 млн	85.73 млн	368 844 %	9 866 479 %
avg_latency_us	0.4653	5403.56	8629.28	1 066 598 %	15 501 440 %
p99_latency_us	0.4749	60 062.83	89 309.91	5 143 905 %	108 288 436 %
throughput_ops_sec	0.4672	1.89 млн	3.27 млн	637 796 %	18 881 916 %


Все метрики находятся ниже порога $R^2 = 0.7$. В отличие от подходов А и В, Ridge в системе С не справился даже с аппроксимацией памяти ($R^2 = 0.6134$). Абсолютный масштаб задержек (десятки и сотни миллисекунд) указывает на присутствие в выборке редких, но тяжелых операций, генерирующих аномальные значения MAPE и Max Error %

Анализ графика «Фактическое vs Предсказанное»




На графике throughput_ops_sec предсказания Ridge выходят на плато, полностью срезая реальные пиковые значения.

Анализ остатков и обоснование перехода на Random Forest



Структура остатков принципиально отличается от А и В: впервые зафиксирована сильная корреляция ошибок `memory_usage_bytes` с латентностями ($r \approx 0.72$, тогда как в А/В связь стремилась к нулю). Взаимосвязь остатков `avg_latency` и `p99` достигла максимума ($r = 0.94$). Это указывает на единый нелинейный источник дисперсии (аномальные пиковые нагрузки), при котором одновременно деградируют временные показатели и скачкообразно растет объем структуры



- **avg_latency_us:** Наблюдается знакомый по А конфликт знаков: `estimated_nodes` (+0.89) против отрицательных весов интерактивных признаков (`nodes_x_mutation`: -0.55)
- **throughput_ops_sec:** Сильнейшим негативным фактором выступает доля листинга `p_ls` (-0.75)
- **memory_usage_bytes:** Обнаружена важная аномалия: доминирующим предиктором памяти стал не геометрический параметр, а предсказанная латентность `mean_latency` (+0.55). Потребление памяти в С динамически зависит от временных задержек файловой системы (например, накопление буферов при долгом ответе)
- **p99_latency_us:** Модель опирается исключительно на предсказания предыдущих шагов: `mean_latency` (+0.77) и `memory` (+0.25)

Провал линейной регрессии на фоне чистых признаков подтверждает необходимость перехода к Random Forest для раскрытия сложных пороговых эффектов


Random Forest: подбор гиперпараметров и оценка

Оптимальная конфигурация: `n_estimators=200`, `max_depth=10`, `max_features=sqrt`, `min_samples_leaf=1`. Порядок цепочки сохранен. OOB R^2 первого звена (`avg_latency_us`) составил 0.9919, подтверждая высокую обобщающую способность


Метрика	R^2	MAE	RMSE	MAPE
memory_usage_bytes	0.9988	1 313 819	4 743 374	101.01 %
avg_latency_us	0.9859	338.82	1 402.37	2533.07 %
p99_latency_us	0.9290	8 797.01	32 839.16	2595.51 %
throughput_ops_sec	0.8808	627 442	1 547 501	579.56 %

Переход к ансамблям продемонстрировал самый сильный скачок качества среди всех подходов. Подход С на базе RF стал лидером по точности аппроксимации временных параметров, существенно опередив и А, и В

Анализ графика «Фактическое vs Предсказанное» (RF)







Точки `avg_latency_us` прилегают к диагонали вплоть до максимумов (60 мс), эффект насыщения устранен. На `p99` и `throughput` сохраняются занижения на больших значениях, но куда меньше чем в линейной модели

Анализ остатков

Корреляция остатков `avg_latency` / `p99_latency` упала с 0.94 до 0.32 (что существенно чище результатов RF в подходах А и В, где оставалось ~ 0.8). Единственной значимой парой осталась взаимосвязь `memory` / `p99_latency` ($r = 0.38$), что обусловлено структурой цепочки

Важность признаков: извлеченные паттерны

Random Forest: Важность признаков по звеньям цепочки



- **avg_latency_us**: Важность распределена между интерактивными признаками nodes_x_read (≈ 0.20), nodes_x_mutation (≈ 0.19) и геометрией (log_estimated_nodes ≈ 0.18). Для хэш-таблицы это затраты на эмуляцию иерархии через префиксы: стоимость префиксного поиска при чтении и массового пересчета ключей-путей при мутациях прямо масштабируется от объема структуры
- **throughput_ops_sec**: Наблюдается тотальное доминирование признака pred_avg_latency_us (≈ 0.41).
- **memory_usage_bytes**: RF исправил аномалию Ridge. Память снова объясняется структурными факторами: nodes_x_mutation (≈ 0.24) и estimated_nodes (≈ 0.22).
- **p99_latency_us**: Демонстрирует наиболее сложную композитную структуру важности. Метрика в равной степени зависит от pred_throughput_ops_sec (≈ 0.23) и pred_avg_latency_us (≈ 0.23), со значимым влиянием nodes_x_read (≈ 0.11) и pred_memory_usage_bytes (≈ 0.09).