

Обоснование выбора сетки

Сетка параметров подбиралась так, чтобы покрыть как типичные, так и граничные режимы работы in-методу файловой системы, но при этом оставить число запусков практически выполнимым. В основной регулярной части используются значения глубины (D), ширины (W) и заполнения (F):

$$D \in \{2, 5, 10\} \quad W \in \{5, 10, 15\} \quad F \in \{0.3, 0.6, 0.95\}$$

Такая сетка даёт три характерных уровня для каждого измерения: малый, средний и большой. Этого достаточно, чтобы увидеть не только локальные колебания, но и общую тенденцию роста стоимости операций при усложнении структуры дерева.

Выбор узлов 2, 5, 10 по глубине и 5, 10, 15 по ширине объясняется тем, что они отражают качественно разные формы дерева. $D = 2$ описывает почти плоскую иерархию, $D = 5$ соответствует умеренно вложенной структуре, а $D = 10$ уже моделирует глубокие каталожные цепочки, где начинают проявляться накладные расходы на проход по пути. Аналогично, $W = 5$ соответствует узкому дереву, $W = 10$ является промежуточным вариантом, а $W = 15$ позволяет увидеть эффект широких директорий, где возрастают затраты на поиск дочернего узла и обход содержимого. Значения $F = 0.3, 0.6$ и 0.95 покрывают разреженный, средний и почти полностью заполненный режимы.

Помимо регулярной части, в коде добавлены corner-case конфигурации: глубокие и узкие деревья (10, 2), (15, 2), (20, 2), (15, 3) и широкие, но неглубокие деревья (2, 30), (2, 50), (3, 30), (3, 50). Это важно, потому что именно на таких формах сильнее всего расходятся свойства реализаций: одни структуры данных лучше ведут себя на длинных путях, другие на широких каталогах. Следовательно, одной только симметричной регулярной сетки было бы недостаточно.

Логарифмическая шкала при визуализации результатов оправдана тем, что стоимость операций и потребление памяти растут неравномерно и в ряде режимов различаются на порядки. Например, переход от умеренной структуры к очень крупной может резко увеличить число узлов и тем самым сделать различия между реализациями плохо различимыми на линейной шкале. Логарифмическая шкала позволяет одновременно видеть и малые, и большие значения, не теряя информации о поведении на “лёгких” конфигурациях и не сжимая их в почти горизонтальную линию.

Отдельно важна оценка времени экспериментов. Для одной пары “файловая система + профиль нагрузки” регулярная сетка уже даёт $3 \times 3 \times 3 \times 3 = 81$ точку, а с добавлением граничных shape-профилей число конфигураций становится ещё больше. При параметрах $repeats = 2$ и $ops = 2000$ один job на практике занимает минуты, а полный набор запусков по нескольким профилям и нескольким реализациям даёт десятки минут wall-clock времени даже при распараллеливании. Иными словами, в текущей постановке мы уже слегка упираемся в производительность доступного железа: дальнейшее механическое уплотнение сетки сразу увеличивает время прогона и требования к ресурсам. Поэтому выбранная конфигурация является рабочим компромиссом между полнотой покрытия и вычислительной стоимостью. При этом само исследование на этом не заканчивается: его можно продолжать и расширять по мере появления доступа к более производительной машине, при более агрессивном распараллеливании или более узко сформулированных гипотезах, для которых имеет смысл локально сгущать сетку только в интересующих областях параметров.

Комбинаторный взрыв и необходимость аппроксимации

Проблема комбинаторного взрыва возникает из-за того, что итоговое число рассматриваемых конфигураций растёт как произведение числа вариантов по каждому измерению. Даже если оставить только основные параметры, получаем произведение по глубине, ширине, заполнению, профилю распределения путей, профилю операций, типу файловой системы, числу повторов и числу операций в прогоне. При добавлении новых уровней хотя бы по одному измерению объём пространства состояний растёт мультипликативно, а не линейно.

В данной задаче полный перебор особенно дорог по двум причинам. Во-первых, каждая точка сетки требует не просто арифметического расчёта, а полноценной генерации синтетической файловой системы, подготовки последовательности операций и последующего прогона на конкретной реализации. Во-вторых, если цель состоит не только в сравнении нескольких заранее заданных конфигураций, но и в рекомендации на произвольных пользовательских параметрах, то заранее промерить все возможные комбинации D , W , F , локальности, распределения и вероятностей операций вообще невозможно: пространство становится слишком большим, а многие параметры по сути непрерывные.

Именно поэтому аппроксимация является единственным практичным путём. Вместо полного перебора всех комбинаций строится суррогатная модель, которая по входным параметрам быстро оценивает ожидаемые метрики: среднюю задержку, хвостовую задержку, память и пропускную способность. Такая модель не обязана идеально воспроизводить поведение системы в каждой точке; её задача в другом: достаточно точно сохранять относительный порядок альтернатив и давать ответ за миллисекунды, а не за минуты или часы реального бенчмарка.

Практический смысл аппроксимации состоит в том, что она переводит задачу из режима “дорогое измерение каждой новой точки” в режим “дешёвый прогноз с выборочной верификацией”. Сначала реальные бенчмарки выполняются на репрезентативной сетке и дают опорные данные. Затем на их основе или на основе инженерных эвристик строится приближённая функция, которая оценивает поведение системы между измеренными точками. После этого пользователь может получать рекомендацию для произвольного набора параметров без запуска полного набора экспериментов.

Таким образом, комбинаторный взрыв здесь не является абстрактной теоретической проблемой, а напрямую ограничивает возможность полного перебора в разумное время. Аппроксимация в такой постановке не просто удобное улучшение, а необходимый инструмент, который делает систему рекомендаций и анализ результатов практически применимыми.

Анализ выбранного метода аппроксимации

Более подробный анализ по мл моделям находится в `ml_model/research.pdf`

На основе анализа специфики задачи для проведения экспериментов были выбраны два метода: линейная регрессия с регуляризацией L2 (Ridge) в качестве базового уровня (baseline) и ансамбль решающих деревьев (Random Forest) в качестве целевой нелинейной модели. Переход к анализу сложной модели обосновывается системой критериев достаточности линейного приближения.

Линейная (Ridge) модель считается математически недостаточной для аппроксимации характеристик файловой системы, если выполняется хотя бы одно из следующих условий:

1. **Критерий детерминации:** R^2 на тестовой выборке < 0.7 хотя бы для одной из четырёх целевых системных метрик
2. **Критерий структуры остатков:** Наличие выраженной систематической структуры или гетероскедастичности в остатках (вместо распределения в виде случайного гауссова шума вокруг нулевой линии на графике “остатки vs предсказание”)

Обоснование выбора:

- **Ожидаемая форма зависимостей**

Из теории алгоритмов и структуры исследуемых подходов (A, B, C) можно выделить следующие особенности:

- ▶ **Нелинейность:** В подходе A время поиска зависит от глубины D и ширины W как $O(D \cdot \log W)$ или $O(D \cdot W)$. Это явно нелинейная зависимость. Чтобы линейная регрессия могла её уловить, мы применим логарифмирование признаков
- ▶ **Экспоненциальный рост:** В подходах B и C групповые операции вроде `ls` или `find` зависят от размера поддерева, который при увеличении коэффициента заполнения F может расти экспоненциально

- **Количество доступных данных**

Согласно плану формирования сетки, мы имеем:

$$N \approx 1000 \text{ точек измерений на один подход}$$

- **Требования к интерпретируемости**

- ▶ **Линейная регрессия** даёт максимальную интерпретируемость: знак и величина коэффициента перед признаком показывают, насколько сильно и в какую сторону меняется метрика при изменении признака
- ▶ **Random Forest** менее прозрачен, но он предоставляет оценку важности признаков. С помощью неё мы сможем построить график и наглядно показать, какой из параметров вносит наибольший вклад

- **Вычислительные ресурсы**

Поскольку обученные модели будут использоваться внутри рекомендателя, хотелось бы иметь хорошую скорость на этапе предсказания

- ▶ Линейная регрессия выполняет только операцию скалярного произведения, что работает мгновенно
- ▶ Обученный Random Forest тратит время только на проход по веткам деревьев фиксированной глубины, что также имеет константную сложность $O(1)$ относительно объема данных

Оба метода легковесны и не потребуют мощных вычислительных ресурсов ни при обучении, ни при работе рекомендателя.

Анализ корреляции между метриками

Анализ на объединённых данных всех подходов проверяет характер связей между метриками: являются ли они линейными или нелинейными монотонными.

Диагностика: Пирсон vs Спирмен

Пара метрик	Pearson	Spearman	Разрыв	R^2 лин.	R^2 квадр.
-------------	---------	----------	--------	------------	--------------


avg_latency vs p99_latency	0.953	0.971	0.018	0.908	0.960
avg_latency vs memory	0.321	0.499	0.178	0.103	0.114
avg_latency vs throughput	-0.111	-0.998	0.887	0.012	0.015
p99_latency vs memory	0.327	0.472	0.144	0.107	0.112
p99_latency vs throughput	-0.113	-0.971	0.858	0.013	0.015
memory vs throughput	-0.169	-0.485	0.316	0.028	0.036

Анализ ключевых паттернов

- **Латентность vs Throughput (критическая нелинейность):** Наблюдается экстремальный разрыв между Пирсоном (≈ -0.11) и Спирменом (≈ -0.99). Связь почти детерминированная, но обратно пропорциональная. Линейная модель (Ridge) принимает эту гиперболу за случайный шум, чем объясняется её провал на throughput ($R^2 < 0.58$). Низкий квадратичный R^2 (0.015) доказывает неэффективность простых полиномов для аппроксимации этой формы связи.
- **avg_latency vs p99_latency (линейный полюс):** Разрыв минимален (0.018), линейная модель сразу объясняет 90.8% дисперсии. Метрики тесно связаны линейно, а их совместные отклонения вызваны внешними факторами (пиковыми нагрузками), а не формой взаимозависимости.
- **Память (структурная автономность):** Связь темогу с обеими латентностями слабая в любой форме (Spearman $\approx 0.47 - 0.50$). Это подтверждает, что объём структуры определяется преимущественно статическими геометрическими параметрами, а не временной динамикой выполнения операций.

Анализ многомерных графиков распределений

Распределение метрик




Средняя латентность и p99 демонстрируют схожую бимодальную структуру: основная масса наблюдений сосредоточена вблизи нуля, а разреженный хвост тянется до больших значений.

Память имеет три выраженные полосы, что отражает дискретность сетки параметров: объём памяти определяется числом узлов и меняется скачкообразно при смене D и W.

Пропускная способность убывает монотонно без явных пробелов - следствие нелинейной связи throughput, которая сглаживает бимодальность латентности.


Анализ совместного распределения задержек (p99 vs avg_latency)

Для детального изучения структуры задержек в области стабильной работы системы (с отсечением экстремальных выбросов по порогу $p99_latency_us < 350$ мкс) были проанализированы разделенные графики рассеяния с единым масштабом осей для подходов A, B и C



1. **Подход А (Наивное дерево)** Большинство точек сгруппировано в безопасной зоне низких задержек (до 5 мкс по `avg_latency` и 50 мкс по `p99`). Однако при усложнении поиска линейная зависимость теряется, и график начинает сильно ветвиться. При росте средней задержки всего до 10–15 мкс происходят резкие скачки `p99` вверх (до 250+ мкс). Это показывает, что наивное дерево теряет стабильность на тяжелых операциях, выдавая непредсказуемые выбросы
2. **Подход В (Гибрид с хэш-таблицей)** График вытянут в строгий вертикальный столб: средняя задержка намертво зажата в узком диапазоне (до 5–7 мкс), но разброс `p99` огромен (до 340+ мкс). За счет поиска за $O(1)$ архитектура отлично сдерживает рост среднего времени ответа. Платой за это становятся редкие, но тяжелые операции (коллизии, рехэширование или инвалидация кэша), которые вызывают огромные всплески хвостовой латентности
3. **Подход С (хэш-таблица)** Здесь видна четкая ступенчатая зависимость - точки собираются в изолированные «островки» в районах 7, 18 и 33 мкс по оси X. Подход деградирует предсказуемо: `p99` растет строго пропорционально средней задержке. Разделение на кластеры указывает на явные шаги в архитектуре (например, переход на новый уровень вложенности или чтение глубоких поддиректорий)

Плотности распределения пропускной способности throughput_ops_sec




На рисунке представлены три scatter plot-а, отображающих зависимость пропускной способности от средней латентности для трёх реализаций.

Заметно влияние деревьев в реализации, при приближении к началу координат увеличивается рассеивание точек.

Исследование профилей памяти

Распределение потребления памяти в зависимости от подхода и фактора заполнения (F)



Подход В демонстрирует самые высокие показатели потребления памяти по всем ключевым метрикам: у него наибольшее медианное значение (более $3 \cdot 10^5$ байт), самый высокий верхний квартиль, а также максимальный среди всех групп единичный выброс, достигающий почти 10^9 байт

Подходы А и С имеют схожие минимальные значения (около 10^3 байт) и сопоставимые нижние границы распределения. Однако подход А имеет более высокую медиану и более широкий межквартильный размах по сравнению с подходом С, что говорит о стабильно большем потреблении памяти в типичных случаях

Подход С выглядит наиболее эффективным с точки зрения экономии ресурсов, так как его медиана находится на самом низком уровне (примерно $1.5 \cdot 10^5$ байт), а основная масса данных сдвинута ниже, чем у остальных подходов. При этом во всех трех архитектурных решениях наблюдаются единичные аномальные выбросы в районе 10^8 – 10^9 байт, что указывает на наличие специфических ресурсоемких сценариев для каждого из вариантов

Оценки моделей

Оценка модели для А:

Метрика	R^2 Ridge	R^2 RF	MAE RF	RMSE RF	MAPE RF
memory_usage_bytes	0.753	1.0000	145468	324847	63.71 %
avg_latency_us	0.270	0.7788	0.96	3.62	46.98 %

p99_latency_us	0.326	0.6968	14.83	51.77	140.72 %
throughput_ops_sec	0.413	0.6578	470530	802484	37.52 %

Метрики качества временных параметров оказались ниже, чем у остальных подходов. Стоит отметить, что интегральные оценки для модели А занижены из-за 1% экспериментальных точек, имеющих экстремально большие значения латентности. Модель плохо уловила тенденцию этого ультра-хвостового распределения в зонах аномальных всплесков. При этом на остальных 99% данных модель демонстрирует стабильную работу и нормальную предсказательную способность, адекватно описывая основную массу распределения.

Оценка модели для В:

Метрика	R^2 Ridge	R^2 RF	MAE RF	RMSE RF	MAPE RF
memory_usage_bytes	0.7459	0.9996	1 618 333	5 450 234	181.09 %
avg_latency_us	0.6034	0.8399	1.27	3.07	32.87 %
p99_latency_us	0.6735	0.8386	27.33	66.27	54.18 %
throughput_ops_sec	0.5538	0.9100	377 639	776 423	25.85 %

Оценка модели для С:

Метрика	R^2 Ridge	R^2 RF	MAE RF	RMSE RF	MAPE RF
memory_usage_bytes	0.6134	0.9988	1 313 819	4 743 374	101.01 %
avg_latency_us	0.4653	0.9859	338.82	1 402.37	2533.07 %
p99_latency_us	0.4749	0.9290	8 797.01	32 839.16	2595.51 %
throughput_ops_sec	0.4672	0.8808	627 442	1 547 501	579.56 %

Вывод: анализ стратегий выбора подходов (А, В, С)

Общие закономерности

При согласовании всех критериев выбор подхода определяется геометрией дерева:

Область параметров	Подход	Примеры профилей нагрузки
Очень малые деревья ($D \leq 2, W \leq 10$)	С	backup, web_server, database
Малые деревья, много ветвей ($D = 2, W \geq 15$)	В (редко А)	backup, web_server
Средние деревья ($3 \leq D \leq 10, W \leq 15$)	А	build_system, file_manager, refactoring, reshaping
Большие деревья ($D \geq 15$ или $W \geq 30$)	В (иногда А)	backup, web_server, большинство профилей при $W = 30 - 50$

Специфичные для баз данных ($D \leq 5, W \leq 15$)	С	database (стабильный приоритет С)
--	---	-----------------------------------

Роль подходов в зависимости от структуры:

- **С** — доминирует на малых глубинах ($D \leq 5$), а для профиля database остается основным выбором вплоть до средних размеров ($D \leq 5, W \leq 15$).
- **А** — универсальный выбор для средних и крупных деревьев ($D \geq 3, W \leq 15$) в большинстве системных профилей.
- **В** — преобладает при экстремальном ветвлении ($W \geq 30$) либо большой глубине ($D \geq 15$).

Влияние профиля нагрузки (profile_name)

- **build_system, file_manager, refactoring, reshaping:** почти всегда выбирают **А**, переключаясь на **В** только при критическом расширении ширины ($W \geq 30$).
- **backup, web_server:** адаптивны - предпочитают **С** для мелких деревьев, **В** при $D = 2, W \geq 15$, и переходят к **А** на средних масштабах.
- **database:** демонстрирует жесткую специфику. Подход **С** эффективен вплоть до $D = 5$. Смена на **А** происходит только при $D = 10, W \geq 10$. Подход **В** практически не востребован.

Влияние стратегии взвешивания

В 90% случаев все внутренние метрики согласованы, но на границах областей заметны различия:

- **memory:** жестко тяготеет к **А**, что указывает на минимальный memory footprint данного подхода.
- **throughput:** чаще других выбирает **С** (для малых деревьев) или **В** (для крупных), обеспечивая пиковую пропускную способность там, где сбалансированная стратегия выбирает **А**.
- **latency** схож с дефолтным **balanced**, но в пограничных ситуациях склоняются к **А** из-за более стабильного времени отклика.

Рекомендации по выбору

Приоритет / Условие	Подход	Контекст применения
Очень малые деревья или СУБД ($D \leq 5$)	С	Оптимально для database, web_server, backup
Сбалансированная производительность	А	Основная масса сценариев ($D \geq 3, W \leq 15$)
Строгая минимизация памяти	А	Эффективен во всех профилях
Максимизация пропускной способности	В / С	С - для малых структур/СУБД В - при ($W \geq 30$ или $D \geq 15$)
Минимизация времени	А / В	А - для средних деревьев; В - для тяжелых/широких

5. Заключение

- **Подход А** - наиболее универсальный компромисс, идеален для экономии памяти и сбалансированных нагрузок на средних/крупных структурах.
- **Подход В** - незаменим для сверхглубоких или сильно разветвленных деревьев, где важна сырая пропускная способность.
- **Подход С** - целевой и высокоэффективный выбор для небольших деревьев.